

Detekcija vozila na slikama pomoću konvolucionih neuronskih mreža

Aleksa Vukadinović

Maša Lazić

Matematički fakultet, Računarska inteligencija

16. jul 2026.

Sažetak

U ovom radu razmatramo problem *detekcije vozila* kao zadatak binarne klasifikacije slika: odlučivanje da li data slika sadrži vozilo. Reprodukujemo dobro utemeljenu paradigmu konvolucionih neuronskih mreža (KNM), implementirajući kompaktnu mrežu u stilu VGG sa normalizacijom po grupama (engl. *batch normalization*) i regularizacijom odbacivanjem (engl. *dropout*). Model je treniran i evaluiran na skupu podataka CIFAR-10, čijih deset klasa preslikavamo u binarne ciljeve *vozilo* i *nije vozilo*. Da bismo kvantifikovali doprinos konvolucione arhitekture, upoređujemo KNM sa dva jednostavnija, samostalno razvijena referentna metoda (logistička regresija i potpuno povezana višeslojna perceptronska mreža) trenirana na sirovim pikselima. KNM postiže tačnost od 97.27% na test skupu i ROC-AUC od 0.9965, čime značajno nadmašuje referentne metode – logističku regresiju (81.56%) i MLP (88.04%) – što potvrđuje vrednost prostornog izdvajanja obeležja za ovaj zadatak.

Sadržaj

1	Uvod i pregled literature	2
1.1	Opis problema	2
1.2	Naučna pozadina i srodni radovi	2
1.3	Doprinos ovog rada	2
2	Opis našeg rešenja	2
2.1	Skup podataka i preslikavanje oznaka	2
2.2	Preprocesiranje i augmentacija podataka	3
2.3	Arhitektura mreže	3
2.4	Funkcija gubitka i optimizacija	3
2.5	Referentne metode	4
2.6	Implementacija	4
3	Eksperimentalni rezultati	4
3.1	Eksperimentalno okruženje	4
3.2	Dinamika treniranja	4
3.3	Kvantitativno poređenje	4
3.4	Analiza grešaka	5
3.5	Kvalitativni rezultati na jednostavnim primerima	6
4	Zaključak	6
	Reproducibilnost i tuđi kod	7

1 Uvod i pregled literature

1.1 Opis problema

Detekcija vozila je suštinski problem računarskog vida sa primenama u autonomnoj vožnji, nadzoru saobraćaja i inteligentnim transportnim sistemima. U svom najopštijem obliku zahteva lokalizaciju svakog vozila na slici pomoću graničnog okvira (engl. *bounding box*). U ovom projektu rešavamo osnovni podproblem – *klasifikaciju prisustva vozila*: za zadatu sliku fiksne veličine treba odlučiti da li ona prikazuje vozilo. Formalno, za sliku $x \in \mathbb{R}^{3 \times 32 \times 32}$ učimo funkciju $f_\theta : \mathbb{R}^{3 \times 32 \times 32} \rightarrow \{0, 1\}$, gde 1 označava „vozilo” a 0 „nije vozilo”. Ovo je diskriminativni gradivni blok na kome se grade detektori zasnovani na sliding window ili region proposals metodama.

1.2 Naučna pozadina i srodni radovi

Upotreba konvolucionih neuronskih mreža za prepoznavanje slika datira još od seminalne arhitekture LeNet koju su predložili LeCun i saradnici [1], a koja je uvela obučive konvolucione i slojeve poduzorkovanja za prepoznavanje rukom pisanih cifara. Savremeni procvat KNM započeo je sa mrežom AlexNet [2], koja je ubedljivo pobedila na takmičenju ImageNet i pokazala da duboke KNM trenirane na grafičkim procesorima uz ReLU nelinearnosti dramatično nadmašuju klasične tokove računarskog vida zasnovane na ručno konstruisanim obeležjima poput histograma orijentisanih gradijenata. Naredni radovi produbili su i regularizovali ove mreže: VGG [3] je pokazao da slaganje malih 3×3 konvolucija daje snažne reprezentacije, dok je ResNet [4] uveo rezidualne veze koje omogućavaju veoma duboke modele. Dve tehnike regularizacije i optimizacije danas su standardne i korišćene su u ovom radu: normalizacija po grupama [5], koja stabilizuje i ubrzava treniranje, i odbacivanje [6], koje smanjuje preprilagođavanje. Za optimizaciju koristimo metodu AdamW (varijantu metode Adam sa razdvojenim opadanjem težina) uz kosinusni raspoređivač stope učenja. Širok pregled ovih ideja dat je u udžbeniku Goodfellow-a i saradnika [7].

Za detekciju vozila na celoj slici (sa lokalizacijom), savremeni sistemi poput Faster R-CNN [8] i YOLO [9] proširuju klasifikacionu KNM osnovu (engl. *backbone*) glavama za predloge regiona ili regresiju po mreži. Naš klasifikator odgovara takvoj osnovi ograničenoj na binarnu odluku vozilo/nije-vozilo i mogao bi se, u principu, ugraditi u detektor sa kliznim prozorom.

1.3 Doprinos ovog rada

Ovaj projekat je *reprodukcija* utemeljene metodologije klasifikacije slika pomoću KNM primenjene na detekciju vozila; ne tvrdimo da je arhitektura nova. Naši konkretni doprinosi su: (i) čista, reproducibilna implementacija mreže u stilu VGG u okviru PyTorch-a za binarnu klasifikaciju vozila; (ii) dve samostalno razvijene referentne metode koje izoluju efekat konvolucija; i (iii) temeljno eksperimentalno poređenje sa standardnim merama, krivama i kvalitativnim vizuelizacijama na jednostavnim test primerima.

2 Opis našeg rešenja

2.1 Skup podataka i preslikavanje oznaka

Koristimo skup podataka CIFAR-10 [10], koji sadrži 60,000 slika u boji veličine 32×32 piksela ravnomerno raspoređenih u deset klasa (50,000 za treniranje, 10,000 za testiranje). Deset originalnih klasa preslikavamo u binarni cilj kao što je prikazano u Tabeli 1. Četiri klase vezane za transport postaju pozitivna klasa (vozilo), a šest klasa životinja postaje negativna klasa (nije vozilo), što daje odnos pozitivnih i negativnih primera od 40%/60%.

Zvanični trening skup od 50,000 slika dodatno se deli u odnosu 90%/10% na trening i validacioni podskup. Validacioni podskup koristi se za izbor modela (čuvamo kontrolnu tačku sa

Tabela 1: Preslikavanje klasa skupa CIFAR-10 u binarni cilj detekcije vozila.

Cilj	Originalne klase CIFAR-10
1 – vozilo	avion, automobil, brod, kamion
0 – nije vozilo	ptica, mačka, jelen, pas, žaba, konj

najvećom validacionom tačnošću); test skup od 10,000 slika koristi se isključivo za završnu evaluaciju koja je ovde prikazana.

2.2 Pretprocesiranje i augmentacija podataka

Sve slike se pretvaraju u tenzore i normalizuju po kanalima koristeći standardne statistike skupa CIFAR-10 ($\mu = (0.4914, 0.4822, 0.4465)$, $\sigma = (0.2470, 0.2435, 0.2616)$). Tokom treniranja primenjujemo dve klasične augmentacije radi poboljšanja generalizacije: nasumično isecanje sa dopunjavanjem od 4 piksela (refleksijom) i nasumično horizontalno preslikavanje. Augmentacija se ne primenjuje pri validaciji niti pri testiranju.

2.3 Arhitektura mreže

Naš model, **VehicleCNN**, jeste kompaktna mreža u stilu VGG. Sastoji se od tri konvoluciona bloka iza kojih sledi klasifikaciona glava. Svaki konvolucionni blok sadrži dve 3×3 konvolucije, od kojih svaku prati normalizacija po grupama i ReLU aktivacija, a završava se slojem maks-objedinjavanja 2×2 koji prepolovljava prostornu rezoluciju. Broj kanala se udvostručuje nakon svakog bloka ($3 \rightarrow 64 \rightarrow 128 \rightarrow 256$), tako da se prostorna veličina smanjuje $32 \rightarrow 16 \rightarrow 8 \rightarrow 4$ dok reprezentacija raste u dubinu. Klasifikator primenjuje globalno usrednjeno objedinjavanje, dva potpuno povezana sloja ($256 \rightarrow 128 \rightarrow 2$) sa ReLU aktivacijom i odbacivanjem ($p = 0.5$) između njih. Težine konvolucija inicijalizovane su Kaiming inicijalizacijom. Mreža ima 1,180,354 obučivih parametara. Arhitektura je sažeta u Tabeli 2.

Tabela 2: Arhitektura **VehicleCNN**. „ConvBlock(c)” označava dve 3×3 konvolucije (svaka Conv–BN–ReLU) iza kojih sledi maks-objedinjavanje 2×2 , sa c izlaznih kanala.

Faza	Sloj	Oblik izlaza
Ulaz	–	$3 \times 32 \times 32$
Blok 1	ConvBlock(64)	$64 \times 16 \times 16$
Blok 2	ConvBlock(128)	$128 \times 8 \times 8$
Blok 3	ConvBlock(256)	$256 \times 4 \times 4$
Glava	Globalno usredn. objedinjavanje	256
Glava	Dropout–Linear(128)–ReLU	128
Glava	Dropout–Linear(2)	2 (logiti)

2.4 Funkcija gubitka i optimizacija

Minimizujemo unakrsno-entropijski gubitak između predviđene raspodele klasa i binarnog cilja. Za sliku sa logitima $z = f_\theta(x)$ i tačnom oznakom y , gde je $p_k = \text{softmax}(z)_k$, gubitak je

$$\mathcal{L}(\theta) = -\log p_y = -\log \frac{\exp(z_y)}{\sum_{k \in \{0,1\}} \exp(z_k)}. \quad (1)$$

Parametri se optimizuju metodom AdamW (stopa učenja 10^{-3} , opadanje težina 10^{-4}) tokom 20 epoha sa veličinom serije 128, uz kosinusni raspoređivač stope učenja.

2.5 Referentne metode

Da bismo procenili koliko konvoluciona struktura doprinosi, implementiramo dve jednostavnije referentne metode na istom binarnom zadatku, koje rade na sirovim „izravnatim” vektorima piksela (3072 obeležja) standardizovanim na sredinu nula i jediničnu varijansu:

- **Logistička regresija:** linearni klasifikator; prirodna donja granica za poređenje.
- **Višeslojni perceptron (MLP):** potpuno povezana mreža sa skrivenim slojevima (256, 128) i *bez konvolucija*. Poređenje KNM sa MLP izoluje korist od deljenja težina i prostorne lokalnosti, jer su oba nelinearni modeli uporedive konceptualne složenosti.

2.6 Implementacija

Sistem je implementiran u programskom jeziku Python koristeći PyTorch i torchvision za KNM, a scikit-learn za referentne metode. Kompletan izvorni kod je javno dostupan u GitHub repozitorijumu projekta, organizovan u ponovo upotrebljiv paket `src/` (konfiguracija, skup podataka, model, mehanizam treniranja) uz skripte komandne linije `train.py`, `baselines.py`, `evaluate.py` i `predict.py`.

3 Eksperimentalni rezultati

3.1 Eksperimentalno okruženje

Svi eksperimenti su izvedeni na jednoj mašini sa sledećom hardverskom i softverskom konfiguracijom:

- **Hardver:** Apple M4 Pro (14 logičkih jezgara), 48 GB objedinjene memorije.
- **Akcelerator:** Apple Metal Performance Shaders (MPS) pozadina; kod takođe podržava NVIDIA CUDA i izvršavanje na procesoru i automatski bira najbolji dostupan uređaj.
- **Operativni sistem:** macOS 26.5.1 (verzija 25F80), arm64.
- **Softver:** Python 3.11.14, PyTorch 2.12.1, torchvision 0.27.1, scikit-learn 1.9.0, NumPy 2.4.6.


KNM je trenirana tokom 20 epoha za približno 4.3 minuta (≈ 12.7 s po epohi). Referentne metode logističke regresije i MLP trenirane su za 1.5 s odnosno 8.3 s.

3.2 Dinamika treniranja

Slika 1 prikazuje trening i validacioni gubitak i tačnost tokom 20 epoha. Trening gubitak monotonno opada, dok validacione krive pokazuju očekivane stohastičke fluktuacije i stabilizuju se oko epohe 14–16. Mali i stabilan razmak između trening i validacione tačnosti ukazuje na to da kombinacija augmentacije podataka, normalizacije po grupama i odbacivanja efikasno kontroliše preprilagođavanje. Najbolja validaciona tačnost (97.36%) dostignuta je u epohi 16; ta kontrolna tačka je zadržana za završnu evaluaciju na test skupu.

3.3 Kvantitativno poređenje

Tabela 3 upoređuje KNM sa dve samostalno razvijene referentne metode na test skupu od 10,000 slika, koristeći tačnost, preciznost, odziv, F_1 meru i ROC-AUC. KNM nadmašuje obe referentne metode po svakoj meri sa velikom razlikom. Konkretno, zamena linearnog modela logističke regresije nelinearnim MLP poboljšava tačnost sa 81.6% na 88.0%, ali dodavanje konvolucione strukture (deljenje težina i prostorna lokalnost) donosi mnogo veći skok na 97.3%. Ovo



Slika 1: Trening i validacioni gubitak (levo) i tačnost (desno) u zavisnosti od epohe.


je u skladu sa literaturom pregledanom u Odeljku 1.2 i potvrđuje da je prostorno izdvajanje obeležja presudni činilac za ovaj zadatak.

Tabela 3: Performanse na test skupu za zadatak binarne detekcije vozila. Najbolja vrednost po koloni je **podebljana**.

Model	Tačnost	Preciznost	Odziv	F_1	ROC-AUC
Logistička regresija	0.8156	0.7906	0.7333	0.7608	0.8790
MLP (bez konvolucija)	0.8804	0.8542	0.8453	0.8497	0.9434
VehicleCNN (naše)	0.9727	0.9686	0.9630	0.9658	0.9965

3.4 Analiza grešaka

Slika 2a prikazuje matricu konfuzije KNM na test skupu. Greške su približno uravnotežene između dva tipa: propuštena vozila naspram slika koje nisu vozila a označene su kao vozila. Preciznost (0.969) i odziv (0.963) su bliski, što ukazuje na to da nema jake pristrasnosti ka bilo kojoj klasi uprkos neravnoteži klasa 40/60. Slike 2b i 2c prikazuju ROC krivu i krivu preciznost–odziv; ROC-AUC od 0.9965 pokazuje da je klasifikator odličan u rangiranju i da se prag odlučivanja može slobodno podešavati za primene koje favorizuju veći odziv ili veću preciznost.



(a) Matrica konfuzije


(b) ROC kriva

(c) Kriva preciznost–odziv

Slika 2: Dijagnostički grafici za KNM na test skupu.

3.5 Kvalitativni rezultati na jednostavnim primerima

Kao što je zahtevano, demonstriramo metodu na jednostavnim, pojedinačno vizuelizovanim test slikama. Slika 3 prikazuje dvanaest nasumično izabranih test slika zajedno sa tačnom oznakom, predviđenom oznakom i predviđenom verovatnoćom $P(\text{vozilo})$. Model klasifikuje jasne primere (automobili, brodovi, kamioni, životinje) sa gotovo izvesnom pouzdanošću, dok teži ili netipični prikazi (npr. avion viđen iz neobičnog ugla) dobijaju predviđanja niže pouzdanosti ali i dalje tačna, što je željeno ponašanje.



Slika 3: Predviđanja KNM na pojedinačnim test slikama. Naslovi prikazuju originalnu klasu CIFAR-10, binarne tačne/predviđene oznake i $P(\text{vozilo})$; zeleni naslovi označavaju tačna predviđanja.

4 Zaključak

Reprodukovali smo standardnu metodologiju konvolucionih neuronskih mreža za klasifikaciju slika i primenili je na binarnu detekciju vozila na skupu podataka CIFAR-10. Naša kompaktna mreža u stilu VGG dostigla je tačnost od 97.27% na test skupu i ROC-AUC od 0.9965, jasno nadmašujući referentne metode logističke regresije (81.6%) i potpuno povezanog MLP (88.0%) koje smo razvili radi poređenja. Kontrolisano poređenje izoluje doprinos konvolucione arhitekture: najveći deo poboljšanja u odnosu na nelinearni MLP potiče upravo od deljenja težina i prostorne lokalnosti, što je u skladu sa objavljenom literaturom.

Ostaje nekoliko ograničenja i mogućih poboljšanja za dalji rad:

- **Detekcija, ne samo klasifikacija.** Trenutni model odlučuje samo *da li* je vozilo prisutno. Proširenje na lokalizaciju vozila graničnim okvirima, npr. integracijom osnove u detektor poput Faster R-CNN ili YOLO, jeste prirodan sledeći korak.

- **Podaci više rezolucije i iz stvarnog sveta.** Slike skupa CIFAR-10 su samo 32×32 . Evaluacija na slikama saobraćaja više rezolucije bolje bi odražavala uslove primene.
- **Snažnije arhitekture i regularizacija.** Rezidualne veze, dublje mreže i savremene strategije augmentacije verovatno bi smanjile deo preostale greške.
- **Finije kategorije vozila.** Razlikovanje *tipova* vozila (automobil naspram kamiona naspram broda) umesto jedne binarne oznake jeste korisno proširenje.

U celini, eksperimenti potvrđuju da je čak i mala KNM snažno i praktično rešenje za detekciju prisustva vozila.

Reproducibilnost i tuđi kod

Sav kod je originalan i napisan od strane autora, uz izuzetak opštepoznatih API-ja biblioteka (PyTorch, torchvision, scikit-learn, Matplotlib, NumPy) korišćenih na standardan, dokumentovan način. Skup podataka CIFAR-10 preuzima se automatski putem torchvision-a sa zvaničnog izvora. Konstante normalizacije skupa CIFAR-10 kao i dizajn u stilu VGG i recept za treniranje (augmentacija podataka, BatchNorm, dropout, AdamW, kosinusni raspoređivač) prate uobičajenu praksu utemeljenu u citiranoj literaturi. Kompletan kod, ovaj dokument i sve slike dostupni su u javnom GitHub repozitorijumu, što omogućava potpunu reprodukciju prikazanih rezultata.

Literatura

- [1] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [2] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 25, pp. 1097–1105, 2012.
- [3] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," in *International Conference on Learning Representations (ICLR)*, 2015.
- [4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, 2016.
- [5] S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," in *International Conference on Machine Learning (ICML)*, pp. 448–456, 2015.
- [6] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A simple way to prevent neural networks from overfitting," *Journal of Machine Learning Research*, vol. 15, no. 1, pp. 1929–1958, 2014.
- [7] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [8] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards real-time object detection with region proposal networks," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 28, 2015.
- [9] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 779–788, 2016.

- [10] A. Krizhevsky, “Learning multiple layers of features from tiny images,” technical report, University of Toronto, 2009.