

Detekcija vozila na slikama pomoću jednostepenog konvolucionog detektora objekata

Aleksa Vukadinović
Maša Lazić
Matematički fakultet, Računarska inteligencija

18. jul 2026.

Sažetak

U ovom radu razmatramo problem *detekcije vozila* u punom smislu: za datu sliku model treba da lokalizuje svako vozilo graničnim okvirom (engl. *bounding box*) i vrati sliku sa uokvirenim vozilima. Implementiramo jednostepeni (engl. *single-stage*) detektor sa anchor kutijama u duhu arhitektura SSD i YOLO, izgrađen od nule u okviru PyTorch-a: konvolucionni backbone svodi sliku na mrežu ćelija 16×16 , a detekciona glava za svaku od 2.304 anchor kutije predviđa ocenu prisustva vozila i četiri pomeraja okvira. Model se trenira na skupu podataka Pascal VOC 2007, čijih sedam klasa vozila preslikavamo u jedinstvenu klasu *vozilo*, uz uparivanje anchor kutija po IoU kriterijumu, unakrsnu entropiju sa izdvajanjem teških negativnih primera (engl. *hard negative mining*) i smooth L_1 regresiju. Na izdvojenom validacionom skupu model postiže AP_{50} od 0,522, sa preciznošću od 0,681 i odzivom od 0,479 na radnom pragu. Iako performanse ne dostižu velike pretrenirane detektore, rezultati pokazuju da kompletna tehnika detekcije objekata (anchor kutije, uparivanje, složena funkcija gubitka, dekodiranje i NMS) funkcioniše i u malom, samostalno razvijenom sistemu, što je i bio cilj rada. Ranije razvijeni binarni klasifikator zadržan je kao referentna tačka i ilustracija zašto klasifikacija cele slike nije dovoljna za ovaj zadatak.

Sadržaj

1	Uvod i pregled literature	2
1.1	Opis problema	2
1.2	Naučna pozadina i srodni radovi	2
1.3	Doprinos ovog rada	2
2	Opis našeg rešenja	2
2.1	Skup podataka i izbor klasa	2
2.2	Pretprocesiranje i augmentacija podataka	3
2.3	Arhitektura mreže	3
2.4	Anchor kutije i uparivanje	4
2.5	Funkcija gubitka i optimizacija	4
2.6	Inferencija	4
2.7	Implementacija	4
3	Eksperimentalni rezultati	4
3.1	Eksperimentalno okruženje	4
3.2	Dinamika treniranja	5
3.3	Kvantitativni rezultati	5
3.4	Analiza grešaka	6
3.5	Kvalitativni rezultati	6

1 Uvod i pregled literature

1.1 Opis problema

Detekcija vozila je suštinski problem računarskog vida sa primenama u autonomnoj vožnji, nadzoru saobraćaja i inteligentnim transportnim sistemima. Za razliku od klasifikacije slike, koja odgovara samo na pitanje *da li* slika sadrži vozilo, detekcija zahteva i odgovor na pitanje *gde*: svako vozilo treba lokalizovati graničnim okvirom. Formalno, za sliku x model uči preslikavanje $x \mapsto \{(b_i, s_i)\}_{i=1}^k$, gde je $b_i \in [0, 1]^4$ okvir (normalizovane koordinate gornjeg levog i donjeg desnog temena), a $s_i \in [0, 1]$ ocena pouzdanosti da okvir sadrži vozilo. Broj objekata k nije unapred poznat, što problem čini strukturno težim od klasifikacije sa fiksnim izlazom.

1.2 Naučna pozadina i srodni radovi

Savremena detekcija objekata izrasla je iz konvolucionih klasifikacionih mreža. Dvostepeni pristupi, počev od R-CNN [1] i kulminirajući sa Faster R-CNN [2], prvo predlažu regione od interesa pa ih klasifikuju. Jednostepeni detektori, poput YOLO [3] i SSD [4], uklanjaju korak predlaganja regiona: slika se deli na mrežu ćelija, a svaka ćelija direktno predviđa okvire i ocene, što daje jednostavniji i brži sistem. Ključni sastojci ove paradigme su *anchor kutije* (skup unapred definisanih okvira različitih veličina i odnosa stranica po ćeliji), uparivanje anchor kutija sa stvarnim objektima po preseku-kroz-uniju (IoU), regresija pomeraja okvira i potiskivanje nemaksimuma (engl. *non-maximum suppression*, NMS) pri inferenciji. Neuravnoteženost pozitivnih i negativnih anchor kutija standardno se rešava izdvajanjem teških negativnih primera [4] ili fokalnim gubitkom [5]. Backbone mreže nasleđuju recepte iz klasifikacije: slaganje malih 3×3 konvolucija [7], normalizaciju po grupama [8] i regularizaciju odbacivanjem [9]; širok pregled daje udžbenik Goodfellow-a i saradnika [11]. Za evaluaciju detekcije standard je srednja prosečna preciznost pri IoU pragu 0,5 (AP_{50}), koju je ustanovilo PASCAL VOC takmičenje [6].

1.3 Doprinos ovog rada

U prethodnoj fazi projekta razvili smo binarni klasifikator vozila nad skupom CIFAR-10; taj model odgovara samo na pitanje prisustva vozila i ne može da ga lokalizuje, pa je zadržan kao referentna tačka u direktorijumu `classification/`. Ovaj rad rešava zadatak u celini. Naši konkretni doprinosi su: (i) jednostepeni detektor sa anchor kutijama implementiran *od nule* u PyTorch-u, bez pretreniranih težina i bez gotovih detekcionih biblioteka; (ii) kompletna tehnika treniranja detektora: generisanje i uparivanje anchor kutija, kodiranje pomeraja, unakrsna entropija sa izdvajanjem teških negativnih primera i smooth L_1 regresija; i (iii) evaluacija standardnim detekcionim merama (AP_{50} , kriva preciznost–odziv) sa kvalitativnim vizuelizacijama. Cilj rada je demonstracija arhitekture i tehnike, a ne takmičenje sa velikim pretreniranim detektorima.

2 Opis našeg rešenja

2.1 Skup podataka i izbor klasa

Koristimo skup podataka Pascal VOC 2007 [6], koji za svaki objekat sadrži klasu i granični okvir u XML formatu, za razliku od skupa CIFAR-10 iz prethodne faze, koji nema anotacije okvira. Spajamo particije *trainval* (5.011 slika) i *test* (4.952 slike) u jedinstven fond od 9.963 slike, pošto se ne poredimo sa zvaničnim VOC rezultatima. Od 20 klasa skupa, sedam klasa vozila preslikavamo u jedinstvenu klasu *vozilo* (Tabela 1); objekti označeni kao *difficult* se preskaču.

Zadržavamo samo slike sa bar jednim vozilom, što daje 3.786 slika, podeljenih na 3.408 za treniranje i 378 za validaciju (podela 90/10 sa fiksnim semenom). Validacioni skup sadrži 597 anotiranih vozila i koristi se za izbor modela i za sve mere u Odeljku 3.

Tabela 1: Preslikavanje klasa skupa VOC2007 u jedinstvenu klasu *vozilo*.

Cilj	Originalne klase VOC2007
vozilo	aeroplane, bicycle, boat, bus, car, motorbike, train

2.2 Pretprocesiranje i augmentacija podataka

Slike se skaliraju na 128×128 piksela i normalizuju po kanalima ImageNet statistikama ($\mu = (0,485; 0,456; 0,406)$, $\sigma = (0,229; 0,224; 0,225)$); koordinate okvira normalizuju se na $[0, 1]$, pa promena razmere ne zahteva posebno preračunavanje. Tokom treniranja primenjujemo tri augmentacije koje očuvavaju konzistentnost okvira: nasumično horizontalno preslikavanje (sa odgovarajućom refleksijom koordinata), kolor džiter (osvetljenost, kontrast, zasićenje, nijansa) i nasumično proširenje platna (engl. *zoom-out*): slika se postavlja na nasumičnu poziciju većeg platna (faktor 1,1–1,6), čime nastaju manji objekti i pomereni konteksti. Augmentacija se ne primenjuje pri validaciji.

2.3 Arhitektura mreže

Naš model, **VehicleDetector**, jednostepeni je detektor sa anchor kutijama. Backbone čine četiri konvoluciona bloka u stilu VGG [7]: svaki blok sadrži dve 3×3 konvolucije, svaku prati normalizacija po grupama [8] i ReLU aktivacija, a prva tri bloka završavaju maks-objedinjavanjem 2×2 . Broj kanala raste $3 \rightarrow 32 \rightarrow 64 \rightarrow 128 \rightarrow 256$, dok se prostorna rezolucija smanjuje $128 \rightarrow 64 \rightarrow 32 \rightarrow 16$, tako da izlazna mapa odlika ima 16×16 ćelija sa korakom od 8 piksela. Detekciona glava počinje zajedničkom 3×3 konvolucijom (256 kanala, ReLU, prostorno odbacivanje [9] sa $p = 0,2$), iza koje slede dve paralelne 1×1 konvolucije: *objectness* grana sa po jednim izlazom po anchor kutiji i *regresiona* grana sa po četiri izlaza po anchor kutiji. Težine su inicijalizovane Kaiming inicijalizacijom, a pomeraj objectness grane na -4 kako bi početne ocene odgovarale retkosti pozitivnih primera. Mreža ima 1.775.821 obučiv parametar. Arhitektura je sažeta u Tabeli 2.

Tabela 2: Arhitektura **VehicleDetector**. „ConvBlock(c)“ označava dve 3×3 konvolucije (svaka Conv–BN–ReLU) sa c izlaznih kanala; prva tri bloka završavaju maks-objedinjavanjem 2×2 .

Faza	Sloj	Oblik izlaza
Ulaz	–	$3 \times 128 \times 128$
Blok 1	ConvBlock(32) + pool	$32 \times 64 \times 64$
Blok 2	ConvBlock(64) + pool	$64 \times 32 \times 32$
Blok 3	ConvBlock(128) + pool	$128 \times 16 \times 16$
Blok 4	ConvBlock(256), bez objedinjavanja	$256 \times 16 \times 16$
Glava	Conv 3×3 – ReLU – Dropout2d	$256 \times 16 \times 16$
Glava	Conv 1×1 (objectness)	$9 \times 16 \times 16$
Glava	Conv 1×1 (regresija)	$36 \times 16 \times 16$

2.4 Anchor kutije i uparivanje

U centru svake od 16×16 ćelija generiše se devet anchor kutija: tri skale (0,25, 0,5 i 0,8 širine slike) puta tri odnosa stranica (1:2, 1:1, 2:1), ukupno 2.304 kandidata po slici. Tokom treniranja svaka anchor kutija dobija oznaku na osnovu IoU sa stvarnim okvirima: pozitivna je ako je $\text{IoU} \geq 0,5$ sa nekim objektom, negativna ako je $\text{IoU} < 0,4$ sa svima, a između se ignoriše. Dodatno, za svaki stvarni objekat anchor kutija sa najvećim IoU uvek postaje pozitivna, čime se garantuje da nijedan objekat ne ostane bez para. Pozitivne kutije dobijaju regresione ciljeve u standardnoj parametrizaciji [2]:

$$t_x = \frac{c_x - a_x}{a_w}, \quad t_y = \frac{c_y - a_y}{a_h}, \quad t_w = \log \frac{w}{a_w}, \quad t_h = \log \frac{h}{a_h}, \quad (1)$$

gde su (c_x, c_y, w, h) centar i dimenzije stvarnog okvira, a (a_x, a_y, a_w, a_h) centar i dimenzije anchor kutije.

2.5 Funkcija gubitka i optimizacija

Gubitak je zbir klasifikacione i regresione komponente. Za klasifikaciju koristimo binarnu unakrsnu entropiju nad objectness logitima. Pošto na jednu pozitivnu kutiju dolazi na stotine negativnih, primenjujemo izdvajanje teških negativnih primera kao kod SSD-a [4]: pored svih N_p pozitivnih kutija, u gubitak ulazi samo $3N_p$ negativnih sa najvećim gubitkom. Za regresiju koristimo smooth L_1 gubitak [2] na pozitivnim kutijama:

$$\mathcal{L} = \frac{1}{N_p} \left(\sum_{i \in \text{Pos} \cup \text{HardNeg}} \text{BCE}(o_i, y_i) + \sum_{i \in \text{Pos}} \text{smooth}_{L_1}(r_i - t_i) \right), \quad (2)$$

gde je o_i objectness logit, $y_i \in \{0, 1\}$ oznaka kutije, r_i predviđeni, a t_i ciljni vektor pomeraja. Parametri se optimizuju metodom AdamW [10] (stopa učenja 10^{-3} , opadanje težina 10^{-4}) tokom 80 epoha sa veličinom serije 16, uz kosinusni raspoređivač stope učenja. Čuva se model sa najmanjim validacionim gubitkom.

2.6 Inferencija

Pri inferenciji se slika propusti kroz mrežu, objectness logiti se preslikaju sigmoidom u ocene $[0, 1]$, a predviđeni pomeraji dekodiraju inverzijom parametrizacije iz Odeljka 2.4 u koordinate okvira. Zadržavaju se okviri sa ocenom iznad praga (podrazumevano 0,5), a preklapajuće detekcije uklanja NMS sa IoU pragom 0,35. Okviri se zatim skaliraju na originalnu veličinu slike i crtaju na njenoj kopiji, koja se snima kao izlaz. Time sistem ispunjava postavku zadatka: za datu sliku vraća istu sliku sa uokvirenim vozilima.

2.7 Implementacija

Sistem je implementiran u programskom jeziku Python koristeći PyTorch i torchvision (skup podataka, NMS operator), a Matplotlib za vizuelizacije. Kod je organizovan u paket `src/` (konfiguracija, skup podataka sa augmentacijama, anchor logika, model, funkcija gubitka, mehanizam treniranja) uz skripte komandne linije `train.py`, `evaluate.py` i `detect.py`, po istoj strukturi kao referentni model. Skup podataka se automatski preuzima pri prvom pokretanju.

3 Eksperimentalni rezultati

3.1 Eksperimentalno okruženje


Svi eksperimenti su izvedeni na jednoj mašini sa sledećom hardverskom i softverskom konfiguracijom:

- **Hardver:** Apple M4 Pro (14 logičkih jezgara), 48 GB objedinjene memorije.
- **Akcelerator:** Apple Metal Performance Shaders (MPS) pozadina; kod takođe podržava NVIDIA CUDA i izvršavanje na procesoru i automatski bira najbolji dostupan uređaj.
- **Operativni sistem:** macOS 26.5.1, arm64.
- **Softver:** Python 3.11, PyTorch 2.13.0, torchvision 0.28.0, Matplotlib, NumPy.

Detektor je treniran tokom 80 epoha za približno 62 minuta (≈ 46 s po epohi) nad 3.408 slika za treniranje.

3.2 Dinamika treniranja

Slika 1 prikazuje ukupan gubitak na trening i validacionom skupu, kao i klasifikacionu i regresionu komponentu, tokom 80 epoha. Obe krive monotono opadaju u prvoj polovini treniranja; validacioni gubitak dostiže minimum od 1,93 u epohi 56, nakon čega blago raste dok trening gubitak nastavlja da opada, što je uobičajen znak početka preprilagođavanja, koji kombinacija augmentacije podataka i odbacivanja drži pod kontrolom (bez njih je u preliminarnim eksperimentima validacioni gubitak divergirao već posle petnaeste epohe). Kontrolna tačka iz epohe 56 zadržana je za sve dalje analize. Regresiona komponenta brzo pada i ostaje mala, što pokazuje da je lokalizacija uparenih kutija relativno lak deo zadatka; dominantan izvor gubitka je klasifikacija anchor kutija.



Slika 1: Ukupan gubitak na trening i validacionom skupu (levo) i komponente gubitka na trening skupu (desno) u zavisnosti od epohe.


3.3 Kvantitativni rezultati

Detektor evaluiramo na validacionom skupu od 378 slika sa 597 anotiranih vozila, standardnom metodologijom PASCAL VOC [6]: detekcija je tačna ako ima $\text{IoU} \geq 0,5$ sa neuparenim stvarnim okvirom, a detekcije se razmatraju u opadajućem redosledu ocena. Prosečna preciznost iznosi $\text{AP}_{50} = 0,522$. Tabela 3 prikazuje mere na radnom pragu od 0,5, a Slika 2 celu krivu preciznost–odziv: do odziva od oko 0,4 model zadržava preciznost iznad 0,8, što znači da su najpouzdanije detekcije gotovo uvek ispravne, dok se za veći odziv preciznost očekivano degradira.

Za kontekst, veliki pretrenirani detektori na punom VOC zadatku postižu AP preko 0,7 po klasi [2, 4], ali uz pretrenirane backbone mreže, ulaze veće rezolucije, više-skalne mape odlika i višestruko duže treniranje. Naš rezultat od 0,522, postignut mrežom od 1,8 miliona parametara treniranom od nule na jednoj radnoj stanici, potvrđuje da implementirana tehnika radi kako treba.

Tabela 3: Performanse detektora na validacionom skupu (597 stvarnih okvira), na radnom pragu pouzdanosti od 0,5.

Model	AP ₅₀	Preciznost	Odziv	F ₁	TP / FP
VehicleDetector (naše)	0,522	0,681	0,479	0,562	286 / 134



Slika 2: Kriva preciznost–odziv na validacionom skupu pri IoU pragu 0,5.

3.4 Analiza grešaka

Kriva na Slici 2 i uvid u pojedinačne greške otkrivaju dva dominantna režima. Prvo, najveći deo propuštenih objekata čine mala vozila: najsitnija anchor skala pokriva četvrtinu širine slike na ulazu od 128×128 , pa objekti od nekoliko desetina piksela nemaju kutiju sa dovoljnim preklapom. Drugo, deo lažno pozitivnih detekcija su duplikati: kutije različitih skala oko istog objekta koje NMS ne ukloni jer im je međusobni IoU ispod praga. Oba režima su direktna posledica dizajna sa jednom rezolucijom mape odlika i rešavaju se više-skalnim glavama kakve koriste SSD i RetinaNet [4, 5].


3.5 Kvalitativni rezultati

Slika 3 prikazuje detekcije na šest validacionih slika, zajedno sa stvarnim okvirima. Model pouzdano uokviruje dominantna vozila (automobil sa ocenom od 100% na drugoj slici), a greši na načine konzistentne sa analizom grešaka: okviri oko bicikla i lokomotive su grubi (prekratka ili pomerena kutija), manja vozila u pozadini ulice ostaju nedetektovana, a avion neobičnog oblika je propušten.

4 Zaključak

Implementirali smo od nule jednostepeni detektor vozila sa anchor kutijama i pokazali da kompletan lanac tehnike detekcije objekata (backbone, anchor kutije, IoU uparivanje, kombinovana funkcija gubitka sa izdvajanjem teških negativnih primera, dekodiranje pomeraja i NMS) funkcioniše u malom, samostalno razvijenom sistemu: model za datu sliku vraća sliku sa uokvirenim vozilima, sa AP₅₀ od 0,522 na izdvojenom validacionom skupu. Time je otklonjeno ključno ograničenje prethodne faze projekta, u kojoj je detekcija bila svedena na klasifikaciju prisustva vozila.

Detections on validation images (green = ground truth, red = prediction)



Slika 3: Detekcije na validacionim slikama: zeleno su stvarni okviri, crveno predviđanja sa ocenom pouzdanosti, na radnom pragu od 0,5.

Ostaje nekoliko ograničenja i mogućih poboljšanja za dalji rad:

- **Više-skalna detekcija.** Jedna mapa odlika 16×16 ograničava i najmanju i najveću veličinu pouzdano detektovanog objekta; glave nad više rezolucija (kao kod SSD-a [4]) ili piramida odlika najizgledniji su put ka boljem odzivu na malim vozilima.
- **Veća rezolucija ulaza.** Ulaz od 128×128 piksela gubi detalje sitnih objekata; već 256×256 bi udvostručio efektivnu rezoluciju mreže ćelija uz umeren računski trošak.
- **Pretreniran backbone i fokalni gubitak.** Inicijalizacija backbone-a težinama pretreniranim na ImageNet-u i zamena izdvajanja teških negativna fokalnim gubitkom [5] standardni su načini da se znatno podigne AP bez promene osnovne arhitekture.
- **Razlikovanje tipova vozila.** Proširenje objectness grane na višeklasnu klasifikaciju (automobil, autobus, motocikl, ...) prirodna je nadogradnja koja zahteva samo širu izlaznu konvoluciju.

U celini, eksperimenti potvrđuju da i kompaktan, samostalno izgrađen jednostepeni detektor predstavlja ispravno i praktično rešenje zadatka lokalizacije vozila na slici.

Literatura

- [1] R. Girshick, J. Donahue, T. Darrell, and J. Malik, “Rich feature hierarchies for accurate object detection and semantic segmentation,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 580–587, 2014.
- [2] S. Ren, K. He, R. Girshick, and J. Sun, “Faster R-CNN: Towards real-time object detection with region proposal networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 28, 2015.

- [3] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 779–788, 2016.
- [4] W. Liu, D. Anguelov, D. Erhan, C. Szegedy, S. Reed, C.-Y. Fu, and A. C. Berg, “SSD: Single shot multibox detector,” in *European Conference on Computer Vision (ECCV)*, pp. 21–37, 2016.
- [5] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 2980–2988, 2017.
- [6] M. Everingham, L. Van Gool, C. K. I. Williams, J. Winn, and A. Zisserman, “The PASCAL visual object classes (VOC) challenge,” *International Journal of Computer Vision*, vol. 88, no. 2, pp. 303–338, 2010.
- [7] K. Simonyan and A. Zisserman, “Very deep convolutional networks for large-scale image recognition,” in *International Conference on Learning Representations (ICLR)*, 2015.
- [8] S. Ioffe and C. Szegedy, “Batch normalization: Accelerating deep network training by reducing internal covariate shift,” in *International Conference on Machine Learning (ICML)*, pp. 448–456, 2015.
- [9] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, “Dropout: A simple way to prevent neural networks from overfitting,” *Journal of Machine Learning Research*, vol. 15, no. 1, pp. 1929–1958, 2014.
- [10] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *International Conference on Learning Representations (ICLR)*, 2019.
- [11] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.